



UNIVERSIDAD NACIONAL AUTÓNOMA
DE MÉXICO

FACULTAD DE CIENCIAS

VISUALIZACIÓN DE PATRONES DE FALLO DE
INFERENCIAS CAUSALES EN GRANDES MODELOS DE
LENGUAJE.

T E S I S

QUE PARA OBTENER EL TÍTULO DE:

LICENCIADA EN CIENCIAS DE LA COMPUTACIÓN

P R E S E N T A:

LAURA ITZEL RODRÍGUEZ DIMAYUGA

TUTOR:

M. en Fil. C. ENRIQUE FRANCISCO SOTO
ASTORGA

2026



Declaración de autoría

Declaro que este trabajo es de mi autoría y que las fuentes utilizadas se encuentran debidamente citadas. Esta es una copia fiel del trabajo, incluyendo las revisiones requeridas por el comité evaluador.

Resumen

[Escribir resumen]

Palabras clave: causalidad, modelos de lenguaje, inferencia causal, CLadder.

Agradecimientos

[Escribir agradecimientos]

Dedicatoria

[Escribir dedicatoria]

Contenido

Índice de figuras

Índice de cuadros

Capítulo 1

Introducción

1.1. Contexto histórico y científico

[Desarrollar el contexto histórico y científico del trabajo.]

1.2. Problema de investigación

[Describir con precisión el problema que aborda la tesis.]

1.3. Objetivos

1.3.1. Objetivo general

Establecer un marco teórico que integre la noción de causalidad de Rosen y la jerarquía causal de Pearl para determinar si los grandes modelos de lenguaje tienen la capacidad de realizar inferencias causales legítimas.

1.3.2. Objetivos específicos

Objetivo específico 1

Objetivo específico 2

Objetivo específico 3

1.4. Preguntas de investigación

1.4.1. Pregunta central

¿Qué criterios permiten distinguir la inferencia causal genuina de una asociación estadística simulada en el lenguaje?

1.4.2. Preguntas secundarias

Pregunta secundaria 1

Pregunta secundaria 2

1.5. Hipótesis

[Formular la hipótesis central y, si corresponde, las hipótesis secundarias.]

1.6. Estructura de la tesis

[Explicar brevemente el contenido de cada capítulo.]

Capítulo 2

Antecedentes

2.1. Definición de causalidad

[Desarrollar las principales definiciones de causalidad.]

2.2. La jerarquía causal de Pearl

Pearl plantea como partida tres habilidades distintas de la cognición: ver, hacer e imaginar o hipotetizar/anticipar(Rosen). [?]

- **Ver.** Nos ayuda a percibir regularidades en nuestro ambiente. Estas Rosen las pondría como la identificación de perceptos.
- **Hacer.** Predecir los efectos provocados por cierta perturbación en el ambiente y tomar una decisión para obtener el resultado deseado. Esto incluye la habilidad de tomar herramientas intencionalmente para lograr el objetivo.
- **Imaginar.** Cuando tenemos una teoría de porque funciona una herramienta o cuando no, podemos hipotetizar y mejorar estas herramientas para futuros escenarios.

Si una de las intenciones de Turing era intentar definir un agente cognitivo en cuanto a las preguntas que puede responder. La intención de Pearl aquí plantea, en cada uno de los niveles, distintas dificultades. Para Pearl un sistema que realmente presente cognición debería ser posible de reproducir estos tres tipos de inferencias causales.

Los tres puntos anteriores representan entonces, la intuición por detrás de la formulación matemática, de dichas relaciones.

■

¿Que es lo que puede hacer un razonador causal? ¿Que puede computar un organismo con un modelo causal, a falta de el, que le permite predecir?

Aquí Rosen diferencia, en cuanto a que el proceso de inferencia de un organismo, no depende solo de su estructura causal sino también viene desde una idea que engloba el completo funcionamiento del organismo, definiendo la cognición y agencia del organismo no solo en la estructura causal del fenómeno que se está tratando de predecir.

2.3. Modelo causal estructural

[Describir los modelos causales estructurales y los grafos causales.]

2.4. Relación de modelado de Rosen

[Presentar la relación de modelado y su vínculo con los sistemas anticipatorios.]

2.5. Integración teórica

[Proponer el criterio para distinguir inferencia causal de simulación predictiva.]

Capítulo 3

Experimentación

3.1. Benchmark CLadder y categorización de preguntas

[Describir el benchmark, sus datos y la clasificación por nivel causal.]

3.2. Selección del subconjunto representativo

[Documentar los criterios de selección del subconjunto por nivel causal.]

3.3. Sistema de evaluación

[Describir la implementación en Python y sus dependencias.]

3.4. Consulta a modelos de lenguaje mediante API

[Documentar los modelos, parámetros, prompts y protocolo experimental.]

3.5. Registro y organización de resultados

[Especificar el formato de respuestas, errores, niveles causales y topologías.]

3.6. Construcción del DAG de patrones de fallo

[Describir la construcción y visualización con `networkx`.]

Capítulo 4

Resultados

4.1. Resultados cuantitativos por nivel causal

[Presentar resultados para L1, L2 y L3.]

4.2. Patrones de fallo por subtipo y topología

[Analizar los patrones observados según el tipo de pregunta y el grafo causal.]

4.3. Visualización y análisis del DAG

[Incluir figuras, tablas y el análisis de la estructura del DAG.]

Capítulo 5

Discusión e interpretación

5.1. Consistencia con la hipótesis

[Interpretar los resultados en relación con la hipótesis de simulación predictiva.]

5.2. Limitaciones y contraargumentos

[Discutir limitaciones metodológicas, amenazas a la validez y contraargumentos.]

5.3. Comparación con trabajos previos

[Comparar los resultados con la literatura revisada.]

Capítulo 6

Conclusiones y trabajo futuro

6.1. Contribuciones principales

[Sintetizar las contribuciones teóricas, metodológicas y empíricas.]

6.2. Implicaciones para el análisis causal de LLMs

[Describir las implicaciones de los resultados.]

6.3. Trabajo futuro

[Proponer líneas de investigación futuras.]

References

- [1] Stefano Bianchini, Moritz Müller, and Pierre Pelletier. Deep learning in science. *arXiv preprint arXiv:2009.01575*, 2020.
- [2] Eivinas Butkus and Nikolaus Kriegeskorte. Causal discovery and inference through next-token prediction. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025.
- [3] Sirui Chen, Mengying Xu, Kun Wang, Xingyu Zeng, Rui Zhao, Shengjie Zhao, and Chaochao Lu. Clear: Can language models really understand causal graphs? In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 6247–6265, 2024.
- [4] Ernest Davis and Scott Aaronson. Testing gpt-4 with wolfram alpha and code interpreter plug-ins on math and science problems. *arXiv preprint arXiv:2308.05713*, 2023.
- [5] Jake Fawkes, Nic Fishman, Mel Andrews, and Zachary C Lipton. The fragility of fairness: Causal sensitivity analysis for fair machine learning. *Advances in Neural Information Processing Systems*, 37:137105–137134, 2024.
- [6] Clark Glymour, Kun Zhang, and Peter Spirtes. Review of causal discovery methods based on graphical models. *Frontiers in Genetics*, Volume 10 - 2019, 2019.
- [7] Joseph Y Halpern. *Actual causality*. MIT Press, 2016.
- [8] Anthony JG Hey, Stewart Tansley, Kristin Michele Tolle, et al. *The fourth paradigm: data-intensive scientific discovery*, volume 1. Microsoft research Redmond, WA, 2009.
- [9] Matthew Ho, Aditya Sharma, Justin Chang, Michael Saxon, Sharon Levy, Yujie Lu, and William Yang Wang. Wikiwhy: Answering and explaining cause-and-effect questions. *arXiv preprint arXiv:2210.12152*, 2022.

- [10] Marius Hobbhahn, Tom Lieberum, and David Seiler. Investigating causal understanding in llms. In *NeurIPS ML safety workshop*, 2022.
- [11] Zhijing Jin, Yuen Chen, Felix Leeb, Luigi Gresele, Ojasv Kamal, Zhiheng Lyu, Kevin Blin, Fernando Gonzalez Adauto, Max Kleiman-Weiner, Mrinmaya Sachan, et al. Cladder: Assessing causal reasoning in language models. *Advances in Neural Information Processing Systems*, 36:31038–31065, 2023.
- [12] Zhijing Jin, Jiarui Liu, Zhiheng Lyu, Mrinmaya Sachan, Rada Mihalcea, Mona Diab, David Ha, et al. Can large language models infer causation from correlation? In *International Conference on Learning Representations*, volume 2024, pages 28663–28679, 2024.
- [13] Emre Kiciman, Robert Ness, Amit Sharma, and Chenhao Tan. Causal reasoning and large language models: Opening a new frontier for causality. *Transactions on Machine Learning Research*, 2023.
- [14] Ross D King, Jem Rowland, Stephen G Oliver, Michael Young, Wayne Aubrey, Emma Byrne, Maria Liakata, Magdalena Markham, Pinar Pir, Larisa N Soldatova, et al. The automation of science. *Science*, 324(5923):85–89, 2009.
- [15] Jiaxuan Li, Lang Yu, and Allyson Ettinger. Counterfactual reasoning: Testing language models’ understanding of hypothetical scenarios. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 804–815, 2023.
- [16] Stephanie Long, Tibor Schuster, and Alexandre Piché. Can large language models build causal graphs? *arXiv preprint arXiv:2303.05279*, 2023.
- [17] Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, 2000.
- [18] Judea Pearl. *Causality*. Cambridge university press, 2009.
- [19] Judea Pearl. The algorithmization of counterfactuals. *Annals of Mathematics and Artificial Intelligence*, 61(1):29–39, 2011.
- [20] Judea Pearl. *Probabilistic reasoning in intelligent systems: networks of plausible inference*. Elsevier, 2014.
- [21] Judea Pearl. Theoretical impediments to machine learning with seven sparks from the causal revolution. *arXiv preprint arXiv:1801.04016*, 2018.

- [22] Judea Pearl, Madelyn Glymour, and Nicholas P Jewell. *Causal inference in statistics: A primer*. John Wiley & Sons, 2016.
- [23] Judea Pearl and Dana Mackenzie. *The book of why: the new science of cause and effect*. Basic books, 2018.
- [24] Derek C Penn and Daniel J Povinelli. Causal cognition in human and nonhuman animals: A comparative, critical review. *Annu. Rev. Psychol.*, 58(1):97–118, 2007.
- [25] Jonas Peters, Dominik Janzing, and Bernhard Schölkopf. *Elements of causal inference: foundations and learning algorithms*. MIT press, 2017.
- [26] Robert Rosen. *Anticipatory Systems: Philosophical, Mathematical, and Methodological Foundations*. IFSR International Series in Systems Science and Systems Engineering №1. Springer, 2 edition, 2012.
- [27] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, and Yoshua Bengio. Toward causal representation learning. *Proceedings of the IEEE*, 109(5):612–634, 2021.
- [28] Ilya Shpitser and Judea Pearl. Identification of conditional interventional distributions. *arXiv preprint arXiv:1206.6876*, 2012.
- [29] Peter Spirtes, Clark N Glymour, and Richard Scheines. *Causation, prediction, and search*. MIT press, 2000.
- [30] Peter Spirtes and Kun Zhang. Causal discovery and inference: concepts and recent methodological advances. In *Applied informatics*, volume 3, page 3. Springer, 2016.
- [31] Vishal Verma, Sawal Acharya, Samuel Simko, Devansh Bhardwaj, Anahita Haghighat, Dominik Janzing, Mrinmaya Sachan, Zhijing Jin, and Yongjin Yang. Causal ai scientist: Facilitating causal data science with large language models. In *NeurIPS 2025 AI for Science Workshop*, 2025.
- [32] David Waldner. *Qualitative Causal Inference and Explanation (Strategies for Social Inquiry)*. Cambridge University Press, 2026.
- [33] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.
- [34] Moritz Willig, Matej Zečević, Devendra Singh Dhama, and Kristian Kersting. Can foundation models talk causality? *arXiv preprint arXiv:2206.10591*, 2022.

- [35] M. Zecevic, Moritz Willig, Devendra Singh Dhami, and Kristian Kersting. Causal parrots: Large language models may talk causality but are not causal. *ArXiv*, abs/2308.13067, 2023.
- [36] Cheng Zhang, Stefan Bauer, Paul Bennett, Jiangfeng Gao, Wenbo Gong, Agrin Hilmkil, Joel Jennings, Chao Ma, Tom Minka, Nick Pawlowski, et al. Understanding causality with large language models: Feasibility and opportunities. *arXiv preprint arXiv:2304.05524*, 2023.

APPENDICES

Apéndice A

Detalles de implementación y material suplementario

A.1. Implementación y código fuente

[Incluir aquí detalles técnicos, fragmentos de código o indicar la ubicación del repositorio.]

A.2. Documentación del repositorio público

[Documentar el repositorio, instrucciones de reproducción y versiones utilizadas.]

A.3. Material suplementario

[Agregar tablas, prompts, resultados completos y material adicional.]