



UNIVERSIDAD NACIONAL AUTÓNOMA
DE MÉXICO

FACULTAD DE CIENCIAS

VISUALIZACIÓN DE PATRONES DE FALLO DE
INFERENCIAS CAUSALES EN GRANDES MODELOS DE
LENGUAJE.

T E S I S

QUE PARA OBTENER EL TÍTULO DE:

LICENCIADA EN CIENCIAS DE LA COMPUTACIÓN

P R E S E N T A:

LAURA ITZEL RODRÍGUEZ DIMAYUGA

TUTOR:

M. en Fil. C. ENRIQUE FRANCISCO SOTO
ASTORGA

2026



Declaración de autoría

Declaro que este trabajo es de mi autoría y que las fuentes utilizadas se encuentran debidamente citadas. Esta es una copia fiel del trabajo, incluyendo las revisiones requeridas por el comité evaluador.

Resumen

[Escribir resumen]

Palabras clave: causalidad, modelos de lenguaje, inferencia causal, CLadder.

Agradecimientos

[Escribir agradecimientos]

Dedicatoria

[Escribir dedicatoria]

Contenido

Declaración de autoría	II
Resumen	III
Agradecimientos	IV
Dedicatoria	V
Lista de figuras	IX
Lista de tablas	X
1. Introducción	1
1.1. Contexto histórico y científico	1
1.2. Problema de investigación	1
1.3. Objetivos	1
1.3.1. Objetivo general	1
1.3.2. Objetivos específicos	1
1.4. Preguntas de investigación	2
1.4.1. Pregunta central	2
1.4.2. Preguntas secundarias	2
1.5. Hipótesis	2
1.6. Estructura de la tesis	2

2. Antecedentes	3
2.1. Definición de causalidad	3
2.2. La jerarquía causal de Pearl	3
2.3. Modelo causal estructural	3
2.4. Relación de modelado de Rosen	3
2.5. Integración teórica	3
3. Experimentación	4
3.1. Benchmark CLadder y categorización de preguntas	4
3.2. Selección del subconjunto representativo	4
3.3. Sistema de evaluación	4
3.4. Consulta a modelos de lenguaje mediante API	4
3.5. Registro y organización de resultados	4
3.6. Construcción del DAG de patrones de fallo	5
4. Resultados	6
4.1. Resultados cuantitativos por nivel causal	6
4.2. Patrones de fallo por subtipo y topología	6
4.3. Visualización y análisis del DAG	6
5. Discusión e interpretación	7
5.1. Consistencia con la hipótesis	7
5.2. Limitaciones y contraargumentos	7
5.3. Comparación con trabajos previos	7
6. Conclusiones y trabajo futuro	8
6.1. Contribuciones principales	8
6.2. Implicaciones para el análisis causal de LLMs	8
6.3. Trabajo futuro	8

References	9
APPENDICES	10
A. Detalles de implementación y material suplementario	11
A.1. Implementación y código fuente	11
A.2. Documentación del repositorio público	11
A.3. Material suplementario	11

Índice de figuras

Índice de cuadros

Capítulo 1

Introducción

1.1. Contexto histórico y científico

[Desarrollar el contexto histórico y científico del trabajo.]

1.2. Problema de investigación

[Describir con precisión el problema que aborda la tesis.]

1.3. Objetivos

1.3.1. Objetivo general

Establecer un marco teórico que integre la noción de causalidad de Rosen y la jerarquía causal de Pearl para determinar si los grandes modelos de lenguaje tienen la capacidad de realizar inferencias causales legítimas.

1.3.2. Objetivos específicos

Objetivo específico 1

Objetivo específico 2

Objetivo específico 3

1.4. Preguntas de investigación

1.4.1. Pregunta central

¿Qué criterios permiten distinguir la inferencia causal genuina de una asociación estadística simulada en el lenguaje?

1.4.2. Preguntas secundarias

Pregunta secundaria 1

Pregunta secundaria 2

1.5. Hipótesis

[Formular la hipótesis central y, si corresponde, las hipótesis secundarias.]

1.6. Estructura de la tesis

[Explicar brevemente el contenido de cada capítulo.]

Capítulo 2

Antecedentes

2.1. Definición de causalidad

[Desarrollar las principales definiciones de causalidad.]

2.2. La jerarquía causal de Pearl

[Presentar los niveles de asociación (L1), intervención (L2) y contrafactuales (L3).]

2.3. Modelo causal estructural

[Describir los modelos causales estructurales y los grafos causales.]

2.4. Relación de modelado de Rosen

[Presentar la relación de modelado y su vínculo con los sistemas anticipatorios.]

2.5. Integración teórica

[Proponer el criterio para distinguir inferencia causal de simulación predictiva.]

Capítulo 3

Experimentación

3.1. Benchmark CLadder y categorización de preguntas

[Describir el benchmark, sus datos y la clasificación por nivel causal.]

3.2. Selección del subconjunto representativo

[Documentar los criterios de selección del subconjunto por nivel causal.]

3.3. Sistema de evaluación

[Describir la implementación en Python y sus dependencias.]

3.4. Consulta a modelos de lenguaje mediante API

[Documentar los modelos, parámetros, prompts y protocolo experimental.]

3.5. Registro y organización de resultados

[Especificar el formato de respuestas, errores, niveles causales y topologías.]

3.6. Construcción del DAG de patrones de fallo

[Describir la construcción y visualización con `networkx`.]

Capítulo 4

Resultados

4.1. Resultados cuantitativos por nivel causal

[Presentar resultados para L1, L2 y L3.]

4.2. Patrones de fallo por subtipo y topología

[Analizar los patrones observados según el tipo de pregunta y el grafo causal.]

4.3. Visualización y análisis del DAG

[Incluir figuras, tablas y el análisis de la estructura del DAG.]

Capítulo 5

Discusión e interpretación

5.1. Consistencia con la hipótesis

[Interpretar los resultados en relación con la hipótesis de simulación predictiva.]

5.2. Limitaciones y contraargumentos

[Discutir limitaciones metodológicas, amenazas a la validez y contraargumentos.]

5.3. Comparación con trabajos previos

[Comparar los resultados con la literatura revisada.]

Capítulo 6

Conclusiones y trabajo futuro

6.1. Contribuciones principales

[Sintetizar las contribuciones teóricas, metodológicas y empíricas.]

6.2. Implicaciones para el análisis causal de LLMs

[Describir las implicaciones de los resultados.]

6.3. Trabajo futuro

[Proponer líneas de investigación futuras.]

References

APPENDICES

Apéndice A

Detalles de implementación y material suplementario

A.1. Implementación y código fuente

[Incluir aquí detalles técnicos, fragmentos de código o indicar la ubicación del repositorio.]

A.2. Documentación del repositorio público

[Documentar el repositorio, instrucciones de reproducción y versiones utilizadas.]

A.3. Material suplementario

[Agregar tablas, prompts, resultados completos y material adicional.]