



1. Título tentativo

Visualización de patrones de fallo de inferencias causales en grandes modelos de lenguaje.

2. Objetivo

Establecer un marco teórico que integra la noción de causalidad de Rosen (2012), la jerarquía causal de Pearl (2009) y el principio ICM de Schölkopf et al. (2021), para demostrar que los LLMs operan exclusivamente en el nivel asociativo y carecen de la representación mecanística que exige una relación de modelado legítima.

2.1. Objetivo Secundario

Validar empíricamente el marco teórico mediante el análisis de los patrones de fallo de los LLMs en el benchmark CLadder (Jin et al., 2023). Construyendo un DAG para la visualización que evidencie que dichos fallos no son aleatorios sino estructuralmente concentrados en los niveles de intervención y contrafactuales, consistentemente con la ausencia de representación mecanística predicha por el marco teórico.

3. Hipótesis

La hipótesis central sostiene que los grandes modelos de lenguaje (LLMs) no son capaces de realizar inferencia causal genuina, sino que operan exclusivamente en el nivel de las asociaciones estadísticas, el primer escalón de la jerarquía causal de Pearl.

4. Pregunta Central

¿Satisfacen los grandes modelos de lenguaje los criterios requeridos para generar modelos causales, o producen únicamente asociaciones estadísticas?

5. Justificación

Causal reasoning is believed to be one of the hallmarks of human intelligence [29, 68]. The ability to draw causal inferences from available information is crucial for scientific understanding and rational decision-making: for example, knowing whether smoking causes cancer might enable consumers to make a more informed decision [17, 18]; assessing the causal effect of a vaccine is essential for effective policy-making during a pandemic [14, 44, 72, 97]; and understanding the interplay behind family background, education and income helps devise effective education policies [10, 11, 30, 73]. Our opening quote therefore mirrors the aspirations of many scientists in artificial intelligence and causal inference: to construct a machine capable of performing sound causal reasoning, and able to answer causal questions at scale and with ease. Recent advances in large language models (LLMs) have brought about a paradigm shift in natural language processing (NLP) and artificial intelligence [7, 15, 39, 56, 76, 103, inter alia]. These transformative developments raise the question of whether these machines are already capable of causal reasoning: Do LLMs understand causality? Jin et al. (2023)

Section: Many kinds of causality. The science of causality is the study of cause and effect relationships, and is a fundamental tool for understanding and reasoning about the world and how it works. Correct causal reasoning is crucial to making correct decisions, building robust systems, and scientific discovery itself. While advances in causal modeling have formalized core concepts of causality, the varying tasks and problems across domains have led different fields to use related but distinct conceptualizations and tools. Here we describe three orthogonal categories of causal approaches and tasks. The first axis (covariance- and logic-based causality) distinguishes methodological approaches that emphasize data analysis from those that emphasize logical reasoning. The second axis (type vs. token causality) 2 focuses on the setting for a causal question: Are we asking about causal relationships in general, such as for a population, or asking questions about specific causes for a specific event. The third axis, presented in Section 2.2 focus on the causal question or task itself: are we interested in inferring new relationships, characterizing the strength of specific known or hypothesized relationships, attributing blame or reward for some outcome, etc. Kiciman et al. (2023)

Otros libros para meter de referencia sobre causalidad:

- Spirtes et al., 2000
- Peters et al., 2017
- Pearl, 2014
- Pearl et al., 2016
- Pearl y Mackenzie, 2018

- Pearl, 2009
- Halpern, 2016

6. Resumen

Esta tesis examina si los grandes modelos de lenguaje (LLMs) satisfacen los criterios requeridos para la inferencia causal, o si únicamente producen asociaciones estadísticas. La hipótesis es que los LLMs no satisfacen los criterios requeridos para la inferencia causal. Debido a que operan sobre una distribución observacional comprimida en *tokens* que les permite producir respuestas casualmente plausibles en el nivel de asociación (L1), pero carecen de la representación mecanística que exigen los niveles de intervención (L2) y contrafactual (L3) de la jerarquía de Pearl (2009). El trabajo integra dos componentes.

El **primero** es un marco teórico que articula, a partir de la relación de modelado de Rosen (2012), el modelo causal de Pearl (2009) y el principio de mecanismos causales independientes de Schölkopf et al. (2021), un criterio formal para distinguir inferencia causal de simulación predictiva. El argumento central es que la distinción no se resuelve con una optimización sino que viene desde la arquitectura; un sistema con comprensión estructural dispone de una representación *meconística*, la capacidad de un sistema de representar internamente las funciones estructurales que determinan el valor de cada variable a partir de sus causas, $X_i := f_i(\text{PA}_i, U_i)$ que componen el modelo causal estructural (SCM) (Pearl, 2000). En cambio, un LLM dispone de una distribución de probabilidad sobre tokens optimizada para predecir texto humano.

El **segundo** es un componente computacional que implementa un programa de evaluación sobre el benchmark CLadder (Jin et al., 2023), diseñado explícitamente sobre la jerarquía causal de Pearl (2009) para evaluar los tres niveles de razonamiento causal en modelos de lenguaje: asociación (L1), intervención (L2) y contrafactual (L3). El programa consulta LLMs mediante API, clasifica sus respuestas según el nivel causal requerido, y construye un grafo acíclico dirigido (DAG) de patrones de fallo que visualiza en qué niveles de la jerarquía causal fallan. La implementación utiliza **networkx** para la construcción del grafo y la API de un LLM para las consultas.

Los resultados empíricos se interpretaran con apoyo del marco teórico para argumentar que los fallos observados no son aleatorios sino estructuralmente consistentes con la hipótesis principal: los LLMs se concentran sistemáticamente en el nivel de asociación (L1) de la jerarquía de Pearl y exhiben un fallo en las relaciones de intervención (L2) y contrafactual (L3).

7. Índice tentativo

1. Introducción

- a)* Contexto histórico y científico del trabajo
- b)* Objetivos y preguntas de investigación
- c)* Hipótesis
- d)* Estructura de la tesis

2. Marco teórico

- a)* Definición de causalidad
- b)* La jerarquía causal de Pearl
- c)* Modelo causal estructural y funciones mecanísticas
- d)* Relación de modelado de Rosen
- e)* Principio de mecanismos causales independientes (ICM)
- f)* Integración teórica y criterio para inferencia causal vs simulación predictiva

3. Metodología

- a)* Benchmark CLadder y categorización de preguntas
- b)* Selección de subconjunto representativo por nivel causal
- c)* Diseño del sistema de evaluación en Python
- d)* Consulta a LLMs mediante API
- e)* Registro de respuestas, niveles causales y topologías del grafo
- f)* Construcción del DAG de patrones de fallo con **networkx**

4. Resultados

- a)* Resultados cuantitativos por nivel causal (L1, L2, L3)
- b)* Patrones de fallo según subtipo y topología del grafo causal
- c)* Visualización y análisis del DAG de patrones de fallo

5. Discusión e interpretación

- a)* Consistencia estructural con la hipótesis de simulación predictiva

- b) Limitaciones y posibles contraargumentos
 - c) Comparación con trabajos previos y argumentos contrarios
- 6. Conclusiones y trabajo futuro
 - a) Contribuciones principales
 - b) Implicaciones para el análisis causal de LLMs
 - c) Recomendaciones para investigación futura
- 7. Anexos
 - a) Detalles de implementación y código fuente
 - b) Documentación del repositorio público en GitHub
 - c) Material suplementario y tablas adicionales

Referencias

- Halpern, J. Y. (2016). *Actual causality*. MiT Press.
- Jin, Z., Chen, Y., Leeb, F., Gresele, L., Kamal, O., Lyu, Z., Blin, K., Gonzalez Adauto, F., Kleiman-Weiner, M., Sachan, M., et al. (2023). Cladder: Assessing causal reasoning in language models. *Advances in Neural Information Processing Systems*, 36, 31038-31065.
- Kiciman, E., Ness, R., Sharma, A., & Tan, C. (2023). Causal reasoning and large language models: Opening a new frontier for causality. *Transactions on Machine Learning Research*.
- Pearl, J. (2000). *Causality: Models, Reasoning, and Inference*. Cambridge University Press.
- Pearl, J. (2009). *Causality*. Cambridge university press.
- Pearl, J. (2014). *Probabilistic reasoning in intelligent systems: networks of plausible inference*. Elsevier.
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). *Causal inference in statistics: A primer*. John Wiley & Sons.
- Pearl, J., & Mackenzie, D. (2018). *The book of why: the new science of cause and effect*. Basic books.
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of causal inference: foundations and learning algorithms*. MIT press.
- Rosen, R. (2012). *Anticipatory Systems: Philosophical, Mathematical, and Methodological Foundations* (2.^a ed.). Springer.
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612-634.
- Spirtes, P., Glymour, C. N., & Scheines, R. (2000). *Causation, prediction, and search*. MIT press.