



1. Título tentativo

Visualización de patrones de fallo de inferencias causales en grandes modelos de lenguaje.

2. Objetivo

Establecer un marco teórico que integre la noción de causalidad de Rosen (2012) y la jerarquía causal de Pearl (2009) para determinar si los grandes modelos de lenguaje (Large Language Models, LLMs) tienen la capacidad de realizar inferencias causales legítimas.

2.1. Objetivo Secundario

Validar empíricamente el marco teórico mediante el análisis de los patrones de fallo de los LLM's en el benchmark CLadder (Jin et al., 2023), que reúne 10 mil muestras construidas a partir de grafos causales con consultas asociacionales, intervencionales y contrafactuales; un motor oráculo produce las respuestas de referencia y luego estas se expresan en lenguaje natural. Se hará una consulta a través de una API a los LLMs para obtener sus respuestas, y se registrarán los patrones de fallo según el nivel causal (L1, L2, L3) y el subtipo de pregunta. Como contribución de este trabajo se planea construir un grafo acíclico dirigido (Directed Acyclic Graph, DAG) para la visualización que evidencie que dichos fallos no son aleatorios sino estructuralmente concentrados en los niveles de intervención y contrafactuales.

3. Hipótesis

La hipótesis central es que los LLMs operan predominantemente en el nivel asociativo (L1) de la jerarquía causal de Pearl (2009), y que sus fallos se concentran en tareas de intervención (L2) y contrafactuales (L3) siendo consistente con la ausencia de representación mecanística, en el sentido de la relación de modelado de Rosen (2012).

4. Pregunta Central

¿Qué criterios establece la integración entre la relación de modelado de Rosen (2012) y la jerarquía causal de Pearl (2009) para distinguir inferencia causal genuina de una asociación estadística simulada en el lenguaje, y en qué medida esa distinción es empíricamente verificable mediante el análisis de patrones de fallo en el benchmark CLadder (Jin et al., 2023).?

5. Justificación

Nuestra capacidad de razonar acerca del mundo y entenderlo viene de encontrar las relaciones de causa y efecto a partir de la experiencia (Pearl, 2009; Rosen, 2012; Spirtes et al., 2000). Esta capacidad de establecer relaciones causales y lógicas entre los eventos del mundo se distingue cualitativamente del asociativismo estadístico (Penn & Povinelli, 2007), y su ausencia en los sistemas de inteligencia artificial ha sido señalada como una limitación estructural fundamental (Li et al., 2023; Zecevic et al., 2023).

A medida que el aprendizaje de máquinas ha avanzado, se ha buscado incorporar estos artefactos computacionales (LLM's o modelos predictivos de patrones de datos) para hacer ciencia: descubrir leyes naturales, automatizar la investigación y acelerar el conocimiento empírico (Hey et al., 2009; King et al., 2009; Verma et al., 2025). Sin embargo, la pregunta de si estos modelos realmente identifican relaciones causales, o si simplemente capturan regularidades estadísticas en los datos de entrenamiento, sigue abierta (Chen et al., 2024; Hobbhahn et al., 2022; Kiciman et al., 2023; Li et al., 2023). Parte de la dificultad radica en que la causalidad no es un concepto universalmente definido, distintas disciplinas han desarrollado conceptualizaciones y herramientas divergentes según el tipo de pregunta causal que buscan responder (Halpern, 2016; Peters et al., 2017). De acuerdo con Kiciman et al. (2023), algunos de los tipos de causalidad que los investigadores han intentado formalizar incluyen:

- **Marco causal:** El conjunto de eventos causales candidatos relevantes para un resultado particular. Los modelos causales estructurales (SCM) requieren que las causas relevantes se incluyan como variables internas al sistema, pero en la práctica los humanos utilizan conocimiento del dominio y sentido común (variables externas) para establecer el marco causal después de que el resultado ocurre.
- **Causalidad necesaria:** Si un evento candidato necesitaba ocurrir para que el resultado sucediera.
- **Causalidad suficiente:** Si la ocurrencia de un evento candidato hubiera llevado al resultado si otros eventos causales hubieran ocurrido de manera diferente.
- **Normalidad:** El grado en el que los eventos causales se alinean con normas estadísticas o normativas

(normas sociales, morales o legales). Cuando los agentes violan normas, típicamente se les juzga como causas más directas de los resultados.

- **Otros factores humanos:** Incluyendo sesgo hacia la acción, manejo de intención y estado epistémico, e interpretación de resultados negativos. Los humanos tienden a atribuir más causalidad a acciones que a omisiones de acciones, y también consideran si el agente actuó con intención y conocimiento de lo que hacía.

Uno de los autores que más ha desarrollado una teoría formal de la causalidad es Judea Pearl (Pearl, 2009), cuyo trabajo surge precisamente de la insatisfacción con la estadística asociativa como único fundamento del razonamiento científico. Pearl critica las limitaciones de los modelos de ecuaciones estructurales (structural equation modeling, SEM), que se restringen a la predicción observacional sin permitir un razonamiento anticipatorio sobre distintos escenarios. Argumenta que las distribuciones de probabilidad, por ricas que sean, son insuficientes para responder las preguntas que realmente importan en ciencia y en toma de decisiones (Pearl, 2009; Pearl & Mackenzie, 2018).

Para articular esta distinción propone una jerarquía de tres niveles: asociación (L1), que captura regularidades observacionales; intervención (L2), que requiere razonar sobre los efectos de manipular el sistema; y contrafactual (L3), que exige imaginar mundos alternativos (hipotéticos) al observado. Cada nivel superior requiere información estructural que el nivel inferior no puede proveer (Pearl, 2018).

Para definir y formalizar la causalidad, Pearl (2009) introduce el concepto de modelo causal. En primer lugar, define la estructura causal como:

Definición 2.2.1 (Estructura causal). *Una estructura causal de un conjunto de variables V es un grafo acíclico dirigido (DAG) en el cual cada nodo corresponde a un elemento distinto de V , y cada arista representa una relación funcional directa entre las variables correspondientes.*

(Traducción propia de Pearl (2009, p. 44)).

Luego define el modelo causal como:

Definición 2.2.2 (Modelo causal). *Un modelo causal es un par $M = \langle D, \Theta_D \rangle$ que consiste en una estructura causal D y un conjunto de parámetros Θ_D compatibles con D . Los parámetros Θ_D asignan una función $x_i = f_i(pa_i, u_i)$ a cada $X_i \in V$ y una medida de probabilidad $P(u_i)$ a cada u_i , donde PA_i son los padres de X_i en D y donde cada U_i es una perturbación aleatoria distribuida de acuerdo con $P(u_i)$, independientemente de todas las demás u .*

(Traducción propia de Pearl (2009, p. 44)).

En este marco, la inferencia causal se define como:

Definición 2.3.1 (Causalidad inferida). *Se dice que una variable X tiene influencia causal sobre una variable Y si existe un camino dirigido de X a Y en toda estructura minimal consistente con los datos.*

(Traducción propia de Pearl (2009, p. 45)).

Schölkopf et al. (2021) señala que la inferencia causal es un requerimiento fundamental para la inteligencia artificial, en especial, para la generalización fuera de distribución. Es decir para crear un sistema que pueda aprender de un entorno y luego aplicar ese conocimiento a otro entorno diferente, lo cual es una capacidad esencial para la inteligencia general. Jin et al. (2023) coloca esta cuestión en el centro del debate contemporáneo sobre LLM's, planteando directamente si estos modelos son capaces de razonamiento causal genuino.

Por otro lado, la noción de causalidad en Rosen (2012) surge de la estructura misma de los sistemas naturales (natural systems, *NS*). Para Rosen, un sistema natural (NS) es una colección de cualidades a las cuales se les pueden imputar relaciones definidas. Las cualidades perceptibles (*percepts*) son los *observables* del sistema, y las relaciones que los vinculan constituyen las *leyes del sistema*, expresadas como ecuaciones de estado. Son precisamente estos vínculos (*linkages*) entre observables los que encarnan la noción de **causalidad**. En este sentido, la causa no es una propiedad primitiva del mundo, sino una relación funcional que emerge de la estructura del sistema natural.

Esta concepción tiene una consecuencia directa para la inteligencia artificial, un sistema que solo aprende distribuciones estadísticas sobre texto no captura los vínculos funcionales reales entre observables del mundo. Para que un modelo sea causalmente legítimo en sentido roseniano, debe preservar la estructura de vínculos del sistema natural que pretende representar mediante la *relación de modelado*: una correspondencia entre la estructura inferencial del sistema formal y la estructura causal del sistema natural. La violación de esta correspondencia es, precisamente, la limitación estructural que esta tesis atribuye a los LLMs.

Existen intentos recientes por integrar representaciones causales estructurales en los LLMs con la expectativa de que logren inferencias causales, sin embargo, estos intentos presentan limitaciones metodológicas importantes: los experimentos se diseñan con lenguaje artificial y clases restringidas de modelos causales estructurales que no capturan la riqueza de las relaciones causales presentes en el lenguaje natural ni en las estructuras causales del mundo real (Butkus & Kriegeskorte, 2025; Li et al., 2023). Esta brecha entre el entorno de evaluación y la complejidad causal del mundo, que cualquier modelo legítimo debería preservar en el sentido de la relación de modelado de Rosen (2012), refuerza la hipótesis de que los resultados favorables reportados subestiman la dificultad real del problema.

Esta tesis adopta una posición teóricamente fundamentada frente a esa ambigüedad, la plausibilidad superficial de las respuestas causales de un LLM no implica comprensión estructural genuina. Un sistema puede simular inferencia causal en el nivel asociativo (L1) sin disponer de la representación mecánica que los niveles de intervención (L2) y contrafactual (L3) exigen. Para establecer este argumento con precisión, se integra un marco teórico conjunto entre: 1) la relación de modelado de Rosen (2012), y la 2) la jerarquía causal de Pearl (2009), y se valida empíricamente mediante el análisis de patrones de fallo en el benchmark CLadder (Jin et al., 2023), diseñado específicamente para evaluar los tres niveles de razonamiento causal en modelos de lenguaje.

6. Índice tentativo

1. Introducción

- a)* Contexto histórico y científico del trabajo
- b)* Objetivos y preguntas de investigación
- c)* Hipótesis

2. Antecedentes

- a)* Definición de causalidad
- b)* La jerarquía causal de Pearl
- c)* Modelo causal estructural
- d)* Relación de modelado de Rosen
- e)* Integración teórica y criterio para inferencia causal vs simulación predictiva

3. Experimentación

- a)* Benchmark CLadder y categorización de preguntas
- b)* Selección de subconjunto representativo por nivel causal
- c)* Diseño del sistema de evaluación en Python
- d)* Consulta a LLMs mediante API
- e)* Registro de respuestas, niveles causales y topologías del grafo
- f)* Construcción del DAG de patrones de fallo con **networkx**

4. Resultados

- a) Resultados cuantitativos por nivel causal (L1, L2, L3)
 - b) Patrones de fallo según subtipo y topología del grafo causal
 - c) Visualización y análisis del DAG de patrones de fallo
- 5. Discusión e interpretación
 - a) Consistencia estructural con la hipótesis de simulación predictiva
 - b) Limitaciones y posibles contraargumentos
 - c) Comparación con trabajos previos y argumentos contrarios
- 6. Conclusiones y trabajo futuro
 - a) Contribuciones principales
 - b) Implicaciones para el análisis causal de LLMs
 - c) Recomendaciones para investigación futura
- 7. Anexos
 - a) Detalles de implementación y código fuente
 - b) Documentación del repositorio público en GitHub
 - c) Material suplementario y tablas adicionales

Referencias

- Butkus, E., & Kriegeskorte, N. (2025). Causal Discovery and Inference through Next-Token Prediction. *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Chen, S., Xu, M., Wang, K., Zeng, X., Zhao, R., Zhao, S., & Lu, C. (2024). CLEAR: Can Language Models Really Understand Causal Graphs? *Findings of the Association for Computational Linguistics: EMNLP 2024*, 6247-6265.
- Halpern, J. Y. (2016). *Actual causality*. MIT Press.
- Hey, A. J., Tansley, S., Tolle, K. M., et al. (2009). *The fourth paradigm: data-intensive scientific discovery* (Vol. 1). Microsoft research Redmond, WA.
- Hobbhahn, M., Lieberum, T., & Seiler, D. (2022). Investigating causal understanding in LLMs. *NeurIPS ML safety workshop*.

- Jin, Z., Chen, Y., Leeb, F., Gresele, L., Kamal, O., Lyu, Z., Blin, K., Gonzalez Adauto, F., Kleiman-Weiner, M., Sachan, M., et al. (2023). Cladder: Assessing causal reasoning in language models. *Advances in Neural Information Processing Systems*, 36, 31038-31065.
- Kiciman, E., Ness, R., Sharma, A., & Tan, C. (2023). Causal reasoning and large language models: Opening a new frontier for causality. *Transactions on Machine Learning Research*.
- King, R. D., Rowland, J., Oliver, S. G., Young, M., Aubrey, W., Byrne, E., Liakata, M., Markham, M., Pir, P., Soldatova, L. N., et al. (2009). The automation of science. *Science*, 324(5923), 85-89.
- Li, J., Yu, L., & Ettinger, A. (2023). Counterfactual reasoning: Testing language models’ understanding of hypothetical scenarios. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, 804-815.
- Pearl, J. (2009). *Causality*. Cambridge university press.
- Pearl, J. (2018). Theoretical impediments to machine learning with seven sparks from the causal revolution. *arXiv preprint arXiv:1801.04016*.
- Pearl, J., & Mackenzie, D. (2018). *The book of why: the new science of cause and effect*. Basic books.
- Penn, D. C., & Povinelli, D. J. (2007). Causal cognition in human and nonhuman animals: A comparative, critical review. *Annu. Rev. Psychol.*, 58(1), 97-118.
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of causal inference: foundations and learning algorithms*. MIT press.
- Rosen, R. (2012). *Anticipatory Systems: Philosophical, Mathematical, and Methodological Foundations* (2.^a ed.). Springer.
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612-634.
- Spirtes, P., Glymour, C. N., & Scheines, R. (2000). *Causation, prediction, and search*. MIT press.
- Verma, V., Acharya, S., Simko, S., Bhardwaj, D., Haghighat, A., Janzing, D., Sachan, M., Jin, Z., & Yang, Y. (2025). Causal AI Scientist: Facilitating Causal Data Science with Large Language Models. *NeurIPS 2025 AI for Science Workshop*.
- Zecevic, M., Willig, M., Dhami, D. S., & Kersting, K. (2023). Causal Parrots: Large Language Models May Talk Causality But Are Not Causal. *ArXiv*, abs/2308.13067. <https://api.semanticscholar.org/CorpusID:261214555>