



1. Título tentativo

Visualización de patrones de fallo de inferencias causales en grandes modelos de lenguaje.

2. Objetivo

Establecer un marco teórico que integra la noción de causalidad de Rosen (2012), la jerarquía causal de Pearl (2009) y el principio ICM de Schölkopf et al. (2021), para demostrar que los LLMs operan exclusivamente en el nivel asociativo y carecen de la representación mecanística que exige una relación de modelado legítima.

2.1. Objetivo Secundario

Validar empíricamente el marco teórico mediante el análisis de los patrones de fallo de los LLMs en el benchmark CLadder (Jin, Chen et al., 2023). Construyendo un DAG para la visualización que evidencie que dichos fallos no son aleatorios sino estructuralmente concentrados en los niveles de intervención y contrafactuales, consistentemente con la ausencia de representación mecanística predicha por el marco teórico.

3. Hipótesis

La hipótesis central sostiene que los grandes modelos de lenguaje (LLMs) no son capaces de realizar inferencia causal genuina, sino que operan exclusivamente en el nivel de las asociaciones estadísticas, el primer escalón de la jerarquía causal de Pearl.

4. Pregunta Central

¿Satisfacen los grandes modelos de lenguaje los criterios requeridos para generar modelos causales, o producen únicamente asociaciones estadísticas?

5. Justificación

Nuestra capacidad de razonar acerca del mundo y entenderlo viene de encontrar las relaciones de causa y efecto a partir de la experiencia (Pearl, 2009; Rosen, 2012). Esta capacidad de establecer relaciones causales y lógicas entre los eventos del mundo se distingue cualitativamente del asociativismo estadístico (Penn & Povinelli, 2007), y su ausencia en los sistemas de inteligencia artificial ha sido señalada como una limitación estructural fundamental.

A medida que el aprendizaje de máquinas ha avanzado, se ha buscado incorporar estos artefactos computacionales (LLM's o modelos predictivos de patrones de datos) para hacer ciencia: descubrir leyes naturales, automatizar la investigación y acelerar el conocimiento empírico (Bianchini et al., 2020; Hey et al., 2009; King et al., 2009; Verma et al., 2025). Sin embargo, la pregunta de si estos modelos realmente identifican relaciones causales, o si simplemente capturan regularidades estadísticas en los datos de entrenamiento, sigue abierta (Halpern, 2016; Hobbhahn et al., 2022; Jin, Liu et al., 2023; Kiciman et al., 2023; Willig et al., 2022; Zhang et al., 2023). Parte de la dificultad radica en que la causalidad no es un concepto universalmente definido, distintas disciplinas han desarrollado conceptualizaciones y herramientas divergentes según el tipo de pregunta causal que buscan responder (Kiciman et al., 2023).

Uno de los autores que más ha desarrollado una teoría formal de la causalidad es Judea Pearl, cuyo trabajo surge precisamente de la insatisfacción con la estadística asociativa como fundamento del razonamiento científico. Pearl argumenta que las distribuciones de probabilidad, por ricas que sean, no permiten responder preguntas sobre intervenciones ni sobre contrafácticos, que son las preguntas que importan en ciencia y en toma de decisiones (Pearl, 2009; Pearl & Mackenzie, 2018). Para articular esta distinción propone una jerarquía de tres niveles: asociación (L1), que captura regularidades observacionales; intervención (L2), que requiere razonar sobre los efectos de manipular el sistema; y contrafactual (L3), que exige imaginar mundos alternativos (hipotéticos) al observado. Cada nivel superior requiere información estructural que el nivel inferior no puede proveer. Schölkopf et al. (2021) extiende este argumento señalando que solo el conocimiento causal permite generalizar más allá de la distribución observada y razonar sobre situaciones hipotéticas. Jin, Chen et al. (2023) sitúan esta jerarquía en el centro del debate contemporáneo sobre LLMs, planteando directamente si estos modelos son capaces de razonamiento causal genuino.

Existen intentos recientes por integrar representaciones causales estructurales en los LLMs con la expectativa de que logren inferencias causales genuinas, sin embargo, estos intentos presentan limitaciones metodológicas importantes: los experimentos se diseñan con lenguaje artificial y clases restringidas de modelos causales estructurales que no capturan la riqueza de las relaciones causales presentes en el lenguaje natural ni en las estructuras causales del mundo real (Butkus & Kriegeskorte, 2025). Esta brecha entre el

entorno de evaluación y la complejidad causal del mundo, que cualquier modelo legítimo debería preservar en el sentido de la relación de modelado de Rosen (2012), refuerza la hipótesis de que los resultados favorables reportados subestiman la dificultad real del problema.

Esta tesis adopta una posición teóricamente fundamentada frente a esa ambigüedad, la plausibilidad superficial de las respuestas causales de un LLM no implica comprensión estructural genuina. Un sistema puede simular inferencia causal en el nivel asociativo (L1) sin disponer de la representación mecánica que los niveles de intervención (L2) y contrafactual (L3) exigen. Para establecer este argumento con precisión, se integran tres marcos teóricos: 1) la relación de modelado de Rosen (2012), 2) la jerarquía causal de Pearl (2009) y 3) el principio de mecanismos causales independientes de Schölkopf et al. (2021), y se valida empíricamente mediante el análisis de patrones de fallo en el benchmark CLadder (Jin, Chen et al., 2023), diseñado específicamente para evaluar los tres niveles de razonamiento causal en modelos de lenguaje.

6. Resumen

Esta tesis examina si los grandes modelos de lenguaje (LLMs) satisfacen los criterios requeridos para la inferencia causal, o si únicamente producen asociaciones estadísticas. La hipótesis es que los LLMs no satisfacen los criterios requeridos para la inferencia causal. Debido a que operan sobre una distribución observacional comprimida en *tokens* que les permite producir respuestas casualmente plausibles en el nivel de asociación (L1), pero carecen de la representación mecánica que exigen los niveles de intervención (L2) y contrafactual (L3) de la jerarquía de Pearl (2009). El trabajo integra dos componentes.

El **primero** es un marco teórico que articula, a partir de la relación de modelado de Rosen (2012), el modelo causal de Pearl (2009) y el principio de mecanismos causales independientes de Schölkopf et al. (2021), un criterio formal para distinguir inferencia causal de simulación predictiva. El argumento central es que la distinción no se resuelve con una optimización sino que viene desde la arquitectura; un sistema con comprensión estructural dispone de una representación *mecánica*, la capacidad de un sistema de representar internamente las funciones estructurales que determinan el valor de cada variable a partir de sus causas, $X_i := f_i(\text{PA}_i, U_i)$ que componen el modelo causal estructural (SCM) (Pearl, 2000). En cambio, un LLM dispone de una distribución de probabilidad sobre tokens optimizada para predecir texto humano.

El **segundo** es un componente computacional que implementa un programa de evaluación sobre el benchmark CLadder (Jin, Chen et al., 2023), diseñado explícitamente sobre la jerarquía causal de Pearl (2009) para evaluar los tres niveles de razonamiento causal en modelos de lenguaje: asociación (L1), intervención (L2) y contrafactual (L3). El programa consulta LLMs mediante API, clasifica sus respuestas según el nivel causal requerido, y construye un grafo acíclico dirigido (DAG) de patrones de fallo que visualiza en qué

niveles de la jerarquía causal fallan. La implementación utiliza **networkx** para la construcción del grafo y la API de un LLM para las consultas.

Los resultados empíricos se interpretaran con apoyo del marco teórico para argumentar que los fallos observados no son aleatorios sino estructuralmente consistentes con la hipótesis principal: los LLMs se concentran sistemáticamente en el nivel de asociación (L1) de la jerarquía de Pearl y exhiben un fallo en las relaciones de intervención (L2) y contrafactual (L3).

7. Índice tentativo

1. Introducción

- a)* Contexto histórico y científico del trabajo
- b)* Objetivos y preguntas de investigación
- c)* Hipótesis
- d)* Estructura de la tesis

2. Marco teórico

- a)* Definición de causalidad
- b)* La jerarquía causal de Pearl
- c)* Modelo causal estructural y funciones mecanísticas
- d)* Relación de modelado de Rosen
- e)* Principio de mecanismos causales independientes (ICM)
- f)* Integración teórica y criterio para inferencia causal vs simulación predictiva

3. Metodología

- a)* Benchmark CLadder y categorización de preguntas
- b)* Selección de subconjunto representativo por nivel causal
- c)* Diseño del sistema de evaluación en Python
- d)* Consulta a LLMs mediante API
- e)* Registro de respuestas, niveles causales y topologías del grafo
- f)* Construcción del DAG de patrones de fallo con **networkx**

4. Resultados

- a) Resultados cuantitativos por nivel causal (L1, L2, L3)
- b) Patrones de fallo según subtipo y topología del grafo causal
- c) Visualización y análisis del DAG de patrones de fallo

5. Discusión e interpretación

- a) Consistencia estructural con la hipótesis de simulación predictiva
- b) Limitaciones y posibles contraargumentos
- c) Comparación con trabajos previos y argumentos contrarios

6. Conclusiones y trabajo futuro

- a) Contribuciones principales
- b) Implicaciones para el análisis causal de LLMs
- c) Recomendaciones para investigación futura

7. Anexos

- a) Detalles de implementación y código fuente
- b) Documentación del repositorio público en GitHub
- c) Material suplementario y tablas adicionales

8. Bibliografía principal

- Spirtes, P., Glymour, C. N., & Scheines, R. (2000). *Causation, prediction, and search*. MIT press
- Peters, J., Janzing, D., & Scholkopf, B. (2017). *Elements of causal inference: foundations and learning algorithms*. MIT press
- Pearl, J. (2014). *Probabilistic reasoning in intelligent systems: networks of plausible inference*. Elsevier
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). *Causal inference in statistics: A primer*. John Wiley & Sons
- Pearl, J., & Mackenzie, D. (2018). *The book of why: the new science of cause and effect*. Basic books
- Pearl, J. (2009). *Causality*. Cambridge university press

- Halpern, J. Y. (2016). *Actual causality*. MIT Press
- Jin, Z., Chen, Y., Leeb, F., Gresele, L., Kamal, O., Lyu, Z., Blin, K., Gonzalez Adauto, F., Kleiman-Weiner, M., Sachan, M., et al. (2023). Cladder: Assessing causal reasoning in language models. *Advances in Neural Information Processing Systems*, 36, 31038-31065
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612-634

Referencias

- Bianchini, S., Müller, M., & Pelletier, P. (2020). Deep learning in science. *arXiv preprint arXiv:2009.01575*.
- Butkus, E., & Kriegeskorte, N. (2025). Causal Discovery and Inference through Next-Token Prediction. *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Halpern, J. Y. (2016). *Actual causality*. MIT Press.
- Hey, A. J., Tansley, S., Tolle, K. M., et al. (2009). *The fourth paradigm: data-intensive scientific discovery* (Vol. 1). Microsoft research Redmond, WA.
- Hobbhahn, M., Lieberum, T., & Seiler, D. (2022). Investigating causal understanding in LLMs. *NeurIPS ML safety workshop*.
- Jin, Z., Chen, Y., Leeb, F., Gresele, L., Kamal, O., Lyu, Z., Blin, K., Gonzalez Adauto, F., Kleiman-Weiner, M., Sachan, M., et al. (2023). Cladder: Assessing causal reasoning in language models. *Advances in Neural Information Processing Systems*, 36, 31038-31065.
- Jin, Z., Liu, J., Lyu, Z., Poff, S., Sachan, M., Mihalcea, R., Diab, M. T., & Scholkopf, B. (2023). Can Large Language Models Infer Causation from Correlation? *ArXiv*, abs/2306.05836. <https://api.semanticscholar.org/CorpusID:259129342>
- Kiciman, E., Ness, R., Sharma, A., & Tan, C. (2023). Causal reasoning and large language models: Opening a new frontier for causality. *Transactions on Machine Learning Research*.
- King, R. D., Rowland, J., Oliver, S. G., Young, M., Aubrey, W., Byrne, E., Liakata, M., Markham, M., Pir, P., Soldatova, L. N., et al. (2009). The automation of science. *Science*, 324(5923), 85-89.
- Pearl, J. (2000). *Causality: Models, Reasoning, and Inference*. Cambridge University Press.
- Pearl, J. (2009). *Causality*. Cambridge university press.
- Pearl, J. (2014). *Probabilistic reasoning in intelligent systems: networks of plausible inference*. Elsevier.
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). *Causal inference in statistics: A primer*. John Wiley & Sons.
- Pearl, J., & Mackenzie, D. (2018). *The book of why: the new science of cause and effect*. Basic books.

- Penn, D. C., & Povinelli, D. J. (2007). Causal cognition in human and nonhuman animals: A comparative, critical review. *Annu. Rev. Psychol.*, 58(1), 97-118.
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of causal inference: foundations and learning algorithms*. MIT press.
- Rosen, R. (2012). *Anticipatory Systems: Philosophical, Mathematical, and Methodological Foundations* (2.^a ed.). Springer.
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612-634.
- Spirtes, P., Glymour, C. N., & Scheines, R. (2000). *Causation, prediction, and search*. MIT press.
- Verma, V., Acharya, S., Simko, S., Bhardwaj, D., Haghighat, A., Janzing, D., Sachan, M., Jin, Z., & Yang, Y. (2025). Causal AI Scientist: Facilitating Causal Data Science with Large Language Models. *NeurIPS 2025 AI for Science Workshop*.
- Willig, M., Zečević, M., Dhami, D. S., & Kersting, K. (2022). Can foundation models talk causality? *arXiv preprint arXiv:2206.10591*.
- Zhang, C., Bauer, S., Bennett, P., Gao, J., Gong, W., Hilmkil, A., Jennings, J., Ma, C., Minka, T., Pawlowski, N., et al. (2023). Understanding causality with large language models: Feasibility and opportunities. *arXiv preprint arXiv:2304.05524*.