



1. Título tentativo

Visualización de patrones de fallo del aprendizaje de relaciones causales en grandes modelos de lenguaje.

2. Objetivo

Establecer un marco teórico que integra la noción de causalidad de Rosen, la jerarquía causal de Pearl y el principio ICM de Schölkopf, para demostrar que los LLMs operan exclusivamente en el nivel asociativo y carecen de la representación mecanística que exige una relación de modelado legítima.

2.1. Objetivo Secundario

Validar empíricamente el marco teórico mediante el análisis de los patrones de fallo de los LLMs en el benchmark CLadder Jin et al., 2023. Construyendo un DAG con *networkx* que evidencie que dichos fallos no son aleatorios sino estructuralmente concentrados en los niveles de intervención y contrafactuales, consistentemente con la ausencia de representación mecanística predicha por el marco teórico.

3. Hipótesis

La hipótesis central sostiene que los grandes modelos de lenguaje (LLMs) no son capaces de realizar inferencia causal genuina, sino que operan exclusivamente en el nivel de las asociaciones estadísticas, el primer escalón de la jerarquía causal de Pearl.

4. Pregunta Central

¿Satisfacen los grandes modelos de lenguaje los criterios requeridos para generar modelos causales, o producen únicamente asociaciones estadísticas?

5. Justificación

6. Resumen

Esta tesis examina si los grandes modelos de lenguaje (LLMs) satisfacen los criterios requeridos para la inferencia causal, o si únicamente producen asociaciones estadísticas. La hipótesis es que los LLMs no satisfacen los criterios requeridos para la inferencia causal. Debido a que operan sobre una distribución

evaluar los tres niveles de razonamiento causal en modelos de lenguaje: asociación (L1), intervención (L2) y contrafactual (L3). El programa consulta LLMs mediante API, clasifica sus respuestas según el nivel causal requerido, y construye un grafo acíclico dirigido (DAG) de patrones de fallo que visualiza en qué niveles de la jerarquía causal fallan. La implementación utiliza `networkx` para la construcción del grafo y la API de un LLM para las consultas.

Los resultados empíricos se interpretaran con apoyo del marco teórico para argumentar que los fallos observados no son aleatorios sino estructuralmente consistentes con la hipótesis principal: los LLMs se concentran sistemáticamente en el nivel de asociación (L1) de la jerarquía de Pearl y exhiben un fallo en las relaciones de intervención (L2) y contrafactual (L3).

7. Plan de Trabajo

El trabajo se organiza en cuatro etapas.

Etap 1. Definiciones y marco teórico. La primera etapa comprende la lectura de las fuentes primarias, así como la redacción completa del capítulo de marco teórico. Las cinco secciones del marco: causalidad, jerarquía de causalidad, modelo causal de Pearl, relación de modelado de Rosen (demasiado ?), bloque integrador.

Etap 2. Mapeo de patrones de fallo causal. Se diseña un sistema de evaluación en Python que descarga el benchmark CLadder, selecciona un subconjunto representativo de preguntas por nivel causal, consulta uno o dos LLMs mediante API, y registra para cada pregunta la respuesta del modelo, la respuesta correcta, el nivel causal (L1, L2, L3), el subtipo de consulta dentro del nivel, por ejemplo, correlación directa en L1, intervención con variable mediadora en L2, o contrafactual con confounder en L3, y la topología del grafo causal subyacente a la pregunta, que en CLadder puede ser una cadena, una bifurcación, un colisionador o una estructura de mediación. Sobre estos resultados se construye el DAG de patrones de fallo utilizando `networkx`, donde cada nodo representa un tipo de razonamiento causal y su color refleja la tasa de error del modelo en ese tipo de pregunta. La implementación se expondrá en un repositorio publico en *Github* y se documentara para garantizar su reproducibilidad. El DAG de patrones de fallo es una herramienta de visualización que permite leer dónde es que la jerarquía causal colapsa el razonamiento de los LLMs, y con qué topología de grafo se asocia cada tipo de fallo.

Etap 3. Análisis e interpretación. La tercera etapa produce el capítulo de discusión. El argumento se construye en dos secciones: primero, mostrar que los patrones de error observados en el DAG son estructuralmente consistentes con la hipótesis de simulación predictiva, mostrando que los errores se concentran en L2 y L3, exactamente donde el marco teórico predice que los LLMs fallarán. Segundo, rebatir contraargu-

mentos, por ejemplo Butkus y Kriegeskorte (2025) muestran un modelo rn entrenado bajo datos sintéticos y limitados.

Etapas 4. Redacción final. Integración de capítulos, correcciones, alineación de formato, anexos.

8. Índice tentativo

1. Introducción

- a) Contexto histórico y científico del trabajo
- b) Objetivos
- c) Hipótesis
- d) Visión general del trabajo

Referencias

- Butkus, E., & Kriegeskorte, N. (2025). Causal Discovery and Inference through Next-Token Prediction. *The Thirty-ninth Annual Conference on Neural Information Processing Systems*.
- Jin, Z., Chen, Y., Leeb, F., Gresele, L., Kamal, O., Lyu, Z., Blin, K., Gonzalez Adauto, F., Kleiman-Weiner, M., Sachan, M., et al. (2023). Cladder: Assessing causal reasoning in language models. *Advances in Neural Information Processing Systems*, 36, 31038-31065.
- Pearl, J. (2000). *Causality: Models, Reasoning, and Inference*. Cambridge University Press.
- Pearl, J. (2009). *Causality*. Cambridge university press.
- Rosen, R. (2012). *Anticipatory Systems: Philosophical, Mathematical, and Methodological Foundations* (2.^a ed.). Springer.
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612-634.